

Proje Önerisi

Proje Adı: Çok-Modlu Deepfake Tespit Sistemi (Görüntü + Ses + Frekans Füzyonu)

Hazırlayan: Batuhan Kaya — 232923023 **Tarih:** 2026

Bir videoyu (.mp4) yükleyip **gerçek mi sahte mi** olduğunu söyleyen bir sistem. Karar tek bir bakış açısıyla değil; videodaki **yüz hareketleri**, **ses** ve **frekans izleri** üç ayrı modelle paralel analiz edilip oylanarak verilir.

1) Problem Tanımı

Deepfake nedir? Üretici yapay zekâ modelleri (GAN, VAE, difüzyon) ile gerçek bir kişinin yüzünü veya sesini taklit ederek üretilen sentetik içeriklerdir. Bu içerikler artık çıplak gözle ayırt edilemeyecek kaliteye ulaştığı için tespit görevi otomatik sistemlere kalmaktadır.

Mevcut tespit yöntemlerinin üç temel zaafı:

- Tek bakış açısına bağımlılık.** Yöntemlerin büyük çoğunluğu yalnızca görüntü piksellerini inceler; ses ve frekans alanı izleri göz ardı edilir.
- Zayıf cross-dataset genellemesi.** Bir veri setinde %97+ doğruluk veren modeller, farklı manipülasyon teknikleriyle üretilmiş veri setlerinde belirgin şekilde düşer.
- Görülmemiş manipülasyona karşı kırılganlık.** Eğitimde olmayan bir teknikle üretilmiş sahteler karşısında başarı çöker.

Bu çalışmanın araştırma sorusu: Bir videodaki **görüntü (yüz)**, **ses** ve **frekans (DCT)** modalitelerini eşzamanlı analiz eden karar-seviyesi füzyon mimarisi, tek modlu yöntemlere kıyasla in-dataset ve cross-dataset performansta ne kadar iyileştirme sağlar?

2) Makale/Tez ve Literatür Taraması

Bu proje **iki çekirdek kaynağa** dayanır. Her ikisinin de tam metni elimizde olup tüm sayısal alıntılar bu metinlerden doğrulanmıştır.

2.1. Qiao et al. (2025)

Alan	İçerik
Yayının Adı	Towards Generalizable Deepfake Detection with Spatial-Frequency Collaborative Learning and Hierarchical Cross-Modal Fusion
Yazarlar	Mengyu Qiao, Runze Tian, Yang Wang
Tarih	Nisan 2025
Yayınlandığı Yer	arXiv:2504.17223
Kullanılan Dataset	FaceForensics++ (c23, c40), Celeb-DF v2, DFDC
Uygulanan Yöntem	Block-wise DCT + Cascaded Multi-scale Convolution + Hierarchical Cross-Modal Fusion
Başarı Metrikleri	FF++ c23: %97.43 Acc / %99.58 AUC · Celeb-DF v2 cross-dataset: 0.7468 AUC

Bu projeye katkısı: Frekans modülünün (Block-wise DCT + multi-scale convolution) tasarımı bu makaleden alınmıştır. Celeb-DF v2 cross-dataset AUC karşılaştırma noktası (0.7468) bu çalışmadan referans alınmıştır.

2.2. Yıldırım (2025)

Alan	İçerik
Yayının Adı	Öz Denetimli Öğrenme Yaklaşımları ile Derin Sahte Ses ve Görüntü Manipülasyonunun Tespiti
Yazar	Merve Yıldırım
Tarih	2025
Yayınlandığı Yer	YÖK Tez Merkezi, Tez No: 957056 (Fırat Üniversitesi, Yüksek Lisans)
Kullanılan Dataset	DFDC (alt küme), Celeb-DF v2, deepfake-and-real-images
Uygulanan Yöntem	RotationNet/ResNet18 SSL + CNN-LSTM (görüntü) + Mel-CNN (ses) + öğrenilebilir-ağırlık ensemble
Başarı Metrikleri	Çok modlu (DFDC): %92.17 Acc / %92.02 F1 · Video (Celeb-DF v2): %89.17 Acc

Bu projeye katkısı: Çok modlu (görüntü + ses) ensemble fikri ve Celeb-DF v2 üzerinde Acc karşılaştırma noktası bu tezden alınmıştır.

2.3. Bu Projenin Konumu

İki referans modern deepfake tespitinin iki farklı çizgisini temsil eder:

- **Qiao et al.** — frekans-uzamsal birleşik öğrenme (tek video modalitesi içinde).
- **Yıldırım** — görüntü + ses çok-modlu ensemble.

Bu proje her iki çizgiyi **birleştirir**: 3 modalitenin (görüntü + frekans + ses) karar-seviyesi füzyonu. Tasarım modalite-eksik veri (yalnız ses, yalnız video) durumunda da çalışır.

3) Dataset

3.1. Kullanılan Veri Setleri

Veri Seti	Modalite	İçerik	Kullanım
FaceForensics++ c23	Video	1000 gerçek + 4000 sahte (Deepfakes, Face2Face, FaceSwap, NeuralTextures)	Birincil eğitim + in-dataset test
ASVspoof 2019 LA	Ses	121k klip (bona-fide + spoofed)	Ses modülü eğitim/test
Celeb-DF v2	Video	590 gerçek + 5639 sahte	Cross-dataset test (eğitime KATILMAZ)
FF++ FaceShifter	Video	1000 sahte (5. manipülasyon)	Yalnız vahşi-doğa testi — eğitime/teste girmedir
FF++ DeepFakeDetection (Google DFD)	Video	~3000 sahte	Yalnız vahşi-doğa testi — eğitime/teste girmedir

FF++ c23'teki 4 sahte alt yöntem orijinal FaceForensics++ benchmark'ıdır. FaceShifter sonradan eklenen 5.

yöntemdir ve eğitim setinden bilinçli olarak dışarıda bırakılmıştır — böylece görülmemiş manipülasyon karşısında modelin nasıl davrandığını ölçebilen kontrollü bir test seti elimizde kalmıştır.

3.2. Veri Bölünmesi

- **Eğitim:** %70 (yalnız FF + c23 + ASVspoof 2019 LA)
- **Doğrulama:** %15
- **Test (in-dataset):** %15 → 751 video
- **Cross-dataset test:** Celeb-DF v2 (tamamı, eğitime hiç dahil değil)

Tüm bölünmeler `configs/config.yaml` ve `src/preprocessing/build_dataset.py` ile sabittir; sabit seed ile yeniden üretilebilir.

3.3. Ön İşleme Adımları

1. Video → kare ayrıştırma: OpenCV, 5 fps
2. Yüz tespiti ve hizalama: MTCNN, 224×224 kırpma
3. Ses ayrıştırma: FFmpeg, 16 kHz mono PCM
4. Mel-spektrogram: 128-bant, hop = 512, $n_{fft} = 2048$
5. Frekans dönüşümü: Block-wise DCT (8×8 blok)
6. Maksimum 150 kare/video; uzun videolarda zamansal alt-örnekleme

Pipeline kodu: `src/preprocessing/`.

3.4. Veri Etiği

Tüm veri setleri akademik kullanım için resmi kaynaklarından edinilmiştir. Proje ders ödevi kapsamında olup yayınlanmayacaktır. Üretilen modeller yalnız savunma amaçlı (tespit) kullanılır; herhangi bir deepfake **üretimi** yapılmamıştır.

4) Problem Hangi Sorunu Çözüyor

4.1. Yaklaşım

Sistem deepfake tespit problemini **3 bağımsız bakış açısıyla** çözer ve bu üç kararı **karar-seviyesi (decision-level) füzyon** ile birleştirir:

Modül	Neye Bakar?	Hangi Modelle?
Görüntü	Yüzdeki mimik, ışık, doku tutarsızlıkları	EfficientNet-B4 + Bi-LSTM
Ses	Robotik / sentetik ses izleri	Mel-Spektrogram + CNN
Frekans	GAN / difüzyon modellerinin yüksek frekansta bıraktığı izler	Block-wise DCT + Multi-scale CNN

Füzyon katmanı üç kuralla karar verir:

1. **EER kalibrasyonu** — her modülün ham olasılığı ortak bir eşiğe çekilir ki " $p = 0.8$ " her modülde aynı şeyi ifade etsin.
2. **AUC²-ağırlıklı oylama** — daha güvenilir modülün (yüksek AUC) oyu daha fazla sayılır.
3. **STRONG_FAKE override** — bir modül çok yüksek güvenle ($p \geq 0.85$) "sahte" derse, diğerleri "gerçek" dese bile karar SAHTE olur. Çünkü **kaçırılmış bir deepfake**, yanlış alarmdan çok daha pahalı bir hatadır.

Uygulama: `src/inference.py → fuse()`.

Neden eğitilebilir hiyerarşik füzyon değil? Referans makaledeki (Qiao et al. 2025) o yöntem her örnekte görüntü + ses + frekans'ın **birlikte** olmasını ister. Bizim veri setlerimiz

heterojen (FF + + ve Celeb-DF sessiz, ASVspoof yalnız ses); o yüzden modalite-eksik durumda da çalışan karar-seviyesi füzyon tercih edildi.

4.2. Başarı Metrikleri

Aşağıdaki tüm sayılar `reports/` altındaki JSON çıktılarından gelir; her satırda kaynak dosya verilmiştir.

Modül Başarıları

Modül	Test AUC	Test Acc	Test F1	Cross AUC (Celeb-DF v2)	Kaynak
Ses (Mel-CNN, ASVspoof)	0.9806	%92.94	0.9594	—	<code>reports/best_audio_test/metrics.json</code> (segment)
Frekans (Block-DCT + Multi-scale)	0.8927	%78.56	0.8522	0.7353	<code>reports/analysis/ablation.json</code> (per-video)
Görüntü (EfficientNet-B4 + BiLSTM)	0.9812	%93.61	0.9588	0.8393	<code>reports/analysis/ablation.json</code> (per-video)

Ses modülü FF + + test setinde değil ASVspoof eval'de ölçüldü (FF + + videoları sessiz); o yüzden segment-seviyesi metrik. Frekans ve görüntü modülleri ise FF + + test setinde **video** **bazında** (751 video) değerlendirildi.

Karar-Seviyesi Füzyon (FF + + c23 Test, 751 video)

Strateji	Accuracy	Recall	Precision	F1
Yalnız görüntü (en güçlü tek modül)	%93.61	—	—	0.9599
Eşit oylama	%93.48	%94.68	%97.10	0.9587
AUC-ağırlıklı	%93.61	%93.68	%98.25	0.9591
AUC-ağırlıklı + STRONG_FAKE override	%94.14	%94.68	%97.93	0.9628

Füzyon, en güçlü tek modülü accuracy'de **+0.53 puan**, F1'de **+0.003 puan** geçen tek konfigürasyondur (kaynak: `reports/fusion_eval/metrics.json` ve `reports/analysis/ablation.json`).

Literatürle Karşılaştırma (Celeb-DF v2)

Çalışma	Yaklaşım	Acc	F1	AUC
Qiao et al. (2025)	Spatial-Freq + Hier. Fusion	—	—	0.7468
Yıldırım (2025)	ResNet18 video (SSL)	%89.17	%89.29	—
Bizim — görüntü	EfficientNet-B4 + BiLSTM	%77.91	0.8608	0.8393

AUC ekseninde görüntü modülümüz çekirdek referans Qiao et al.'ı **+9.25 puan** aşmaktadır ($0.8393 > 0.7468$). Her ikisi de aynı protokol altında çalışır: FF + + ile eğit → Celeb-DF v2'de cross-dataset test.

Accuracy ekseninde Yıldırım'ın %89.17 değeri kafa karıştırıcı görünebilir; fakat tezinde (Bölüm 5.3) açıkça belirtildiği üzere "**Celeb-DF v2 alt kümesi üzerinde sıfırdan eğitim yapılmış**" — yani bu sayı **in-dataset** sonucudur, cross-dataset değil. Bizim %77.91 ise FF + + eşığıyla Celeb-DF v2 üstündeki saf cross-dataset

performansı. İki sayı doğrudan karşılaştırılmaz. AUC eksenini (0.8393) ise eşik bağımsız olduğu için bu kalibrasyon farkından da etkilenmez ve karşılaştırma için daha adil bir eksenidir.

Hata Metrikleri — Modül Bazında EER

EER (Equal Error Rate), FPR = FNR olduğu noktadaki ortak hata oranıdır; eşik bağımsız, sınıf-dengesizliğinden bağımsız bir model kalitesi göstergesidir.

Modül	EER (in-dataset)	EER (Celeb-DF v2 cross)	Kaynak
Ses	0.0706	—	reports/best_audio_test/metrics.json
Frekans	0.2208	0.3295	reports/best_frequency_*/metrics.json
Görüntü	0.0616	0.2461	reports/best_spatial_*/metrics.json

Hata Metrikleri — Füzyon (FF++ c23 Test, Üretim Eşiği)

Karışıklık matrisi (kaynak: reports/fusion_eval/metrics.json):

	Tahmin: GERÇEK	Tahmin: SAHTE
Gerçek: GERÇEK	138 (TN)	12 (FP)
Gerçek: SAHTE	32 (FN)	569 (TP)

Hata Türü	Değer	Açıklama
FPR (False Positive Rate)	12/150 = %8.00	Gerçek videoyu sahte sayma
FNR (False Negative Rate)	32/601 = %5.32	Kaçırılmış deepfake (en kritik hata)
Toplam hata	44/751 = %5.86	Genel yanlış sınıflandırma

Tasarım kararı (§4.1 — STRONG_FAKE override) FNR'yi minimize etmeye yöneliktir; kaçırılmış bir deepfake, yanlış alarmlardan çok daha maliyetli bir hata olarak değerlendirilmiştir.

Görülmemiş Manipülasyon Testi (Vahşi-Doğa)

Eğitim ve test setine HİÇ girmemiş 5 kaynaktan rastgele seçilmiş 100 video (seed=7, kaynak: reports/analysis/wild_test.json):

Kaynak	Doğru	Oran
FF++ original (gerçek, eğitim-dışı kimlikler)	20/20	%100
Celeb-DF Celeb-real (gerçek)	17/20	%85
FF++ DeepFakeDetection (sahte, Google DFD)	14/20	%70
Celeb-DF Celeb-synthesis (sahte)	12/20	%60
FF++ FaceShifter (görülmemiş manipülasyon)	1/20	%5
Genel	64/100	%64.0

Bulgu: Gerçek-tanım sağlam (%92.5 = 37/40); fakat eğitimde görülmeyen bir manipülasyon tekniği

(FaceShifter) karşısında model neredeyse kör (%5). Bu sonuç §1)'de 3. zaaf olarak tanımlanan "görülmemiş manipülasyona karşı kırılabilirlik" problemini sayısal olarak doğrular — model deepfake değil, eğitimde gördüğü 4 tekniğin parmak izini tespit etmektedir.

5) Kodların Bulunduğu GitHub Linki

<https://github.com/batuankaya/deepfake-detection>

Yeniden üretim için repodaki ana dosyalar:

- `configs/config.yaml` — model ve eğitim parametreleri
- `scripts/` — CLI tahmin, başlatıcılar ve analiz scriptleri
- `reports/analysis/` — Bölüm 4.2'deki tüm sayıların ham JSON kaynakları
- `app/streamlit_app.py` — son kullanıcı web arayüzü (.mp4 yükle → gerçek/sahte tahmini)
- `README.md` — kurulum ve çalıştırma rehberi